

第三章 基于思想树的文献价值结构化度量

3.1 引言

科学出版物中所蕴含的价值是资源分配^[204, 172, 205]、科学奖励^[206]、研究方向选择^[207, 108]等的决策过程中的关键依据。然而，随着科学事业的加速发展，科学文献的数量正在迅速增加，人们无法阅读所有文献然后再选择有价值的创意^[208, 103]。这限制了资助、奖励和个人研究产出的质量，从而间接减缓了科学事业的进步^[104, 209]。引用次数^[40, 41]因其简单易用性，是目前最广泛使用的文献评价指标。但它仅捕捉到单个出版物的部分结构特征，而忽略了与之相关的更复杂的引用结构，因此为选择最优科学文献提供了一个次优的结果^[210, 211, 212]。

基于网络科学的方法由于能够捕获更丰富的结构信息被用来对文献的价值进行度量。Chen 等人直接使用网络科学中经典的 PageRank 算法^[89]评估 1893 年到 2003 年发表在《物理评论》期刊的所有文章的重要性^[90]。Yin 等人使用 PageRank 算法筛选重要论文作为文献分析系统的输入^[92]。Soler 利用引文网络模拟知识流动，并通过一个基于引用的函数来衡量目标出版物的创造性^[213]。在引文网络中，主要路径的知识流动也被用来追踪特定研究领域的发展，这通常被称为主要路径分析（Main Path Analysis）^[214, 215]。类似于主要路径分析，本章利用引用网络中有效知识流动层的数量来量化目标出版物的发展程度，并使用科学文献中的知识价值会随时间流逝逐渐变得过时作为评估目标出版物未来发展潜力的基础。

对于科学文献的过时性，Burton 和 Kebler 首次引入了一个类似于放射性同位素“半衰期”的概念来描述科学出版物的老化^[72]。1970 年，Brooks 提出了文献生命周期的经典负指数方程^[73]。他发现论文的引用频率随时间的衰减大致遵循负指数方程。Price 指数也是一个著名的用于衡量文献老化速度的指标^[74]。在特定的科学领域，它被定义为最近 5 年发表的文章的引用次数与所有文章引用次数的比率。随着数字信息资源的迅速增加，对科学文献生命周期的研究转向了更大的数据量和更丰富的研究对象^[77, 78, 79]。基于科学出版物将不断变得过时的事实，本章所提框架通过度量目标论文的关键后继者知识的老化以衡量目标出版物的发展潜力。

本章主要探索如何利用科学文献所关联的复杂引用结构实现文献价值的精准度量与直观呈现。广泛应用的引用数只能捕获部分结构信息，科学文献所关联的复杂且不断演化的网络结构中蕴含更丰富的信息，利用网络科学的方法有效利用这些信息有望实现更精准的文献价值度量；提取并以可视化的形式呈现目标论文的思想演化的关键路径能够使用户感知目标文献的思想传承情况，这可以帮助用户直观理解目标文献的价值。基于此，本章提出科学 X 光 (Scientific X-ray)，一个基于引用思想树的文献价值结构化度量方法。科学 X 光扫描与目标出版物相关的引用网络，并通过提取目标出版物激发的引用思想树以重现目标出版物想法的演化，从而呈现并量化目标出版物想法的发展程度以及未来发展的潜力。本章的主要贡献总结如下：

- 本章设计了基于论文结构相似度的思想树提取方法。科学 X 光通过保留由目标论文与施引论文所组成的引用网络中的最关键引用实现思想树的提取。科学 X 光利用结构熵度量思想树中施引论文的知识质量以高亮思想树知识演化过程中的有效层。
- 基于思想树的有效层的数量，本章设计了有效深度 (Valid Depth, VD) 指标以度量目标文献的发展程度。基于思想树中文章的知识质量存在老化这一事实，本章通过评估思想树的有效深度还能增加多少设计了发展潜力指标 (Development Potential Index, DPI) 以评估目标论文的发展潜力。
- 本章从科学 X 光的解析结果中观察到了科学出版物思想的演化规律。科学 X 光的解析结果显示，尽管出版物的引用次数可能不断增加，但这些目标出版物的最大有效思想继承次数难以超过六跳的限制，且绝大多数出版物的思想演化结构均被归入到六个固定模式中。本章还利用奖项数据验证了科学 X 光的有效性。例如，科学 X 光能够在颁奖前成功在 49 个诺贝尔奖主题中将其中的 40 个识别为高发展潜力主题。

本章所使用的数据和代码可以在 https://github.com/liqilcn/scientific_x-ray 中找到。本章的其余部分组织如下。第 3.2 节详细介绍了科学 X 光框架。第 3.3 节介绍了利用科学 X 光发现的文献思想的演

化模式并设计实验验证了科学 X 光的有效性。第 3.4 节使用科学 X 光评估了特定领域的文献发展潜力并进行了讨论。最后在第 3.5 节总结和展望本章的研究内容。




Figure 3-9 The overall framework of Scientific X-ray.

3.2 科学 X 光的框架设计

3.2.1 科学 X 光框架简介

科学 X 光首先检索目标出版物及其施引论文（图 3-9（a）），然后构建由它们引领的引用网络（图 3-9（b））。具体而言，这种类型的引用网络由单个引领论文、引用引领论文的文章、引领论文与引用文章之间的所有引用关系以及引用文章之间的所有引用关系组成。由高影响力目标出版物引领的引用网络的可视化结果显示（图 3-10），不同类型的引领文章的想法




图 3-10 高影响力论文引领的引文网络的可视化结果。节点大小与网络中的入度成正比，节点颜色表示对应论文所属的研究社区。(a-f) 所示的网络分别由以下论文引领：“(a) Applied Predictive Modeling^[216]”，“(b) A survey of deep neural network architectures and their applications^[217]”，“(c) PyTorch: An Imperative Style, High-Performance Deep Learning Library^[218]”，“(d) Improved Training of Wasserstein GANs^[219]”，“(e) FlowNet 2.0: Evolution of Optical Flow Estimation with Deep Networks^[220]” and “(f) Context Encoders: Feature Learning by Inpainting^[221]”。

Figure 3-10 Visualization of the citation network led by high-impact papers. The node size is proportional to the in-degree in the network, and the node color indicates the research community to which the corresponding paper belongs. The networks shown in (a-f) are led by the following papers: ‘(a) Applied Predictive Modeling^[216]’, ‘(b) A survey of deep neural network architectures and their applications^[217]’, ‘(c) PyTorch: An Imperative Style, High-Performance Deep Learning Library^[218]’, ‘(d) Improved Training of Wasserstein GANs^[219]’, ‘(e) FlowNet 2.0: Evolution of Optical Flow Estimation with Deep Networks^[220]’ and ‘(f) Context Encoders: Feature Learning by Inpainting^[221]’.

会以不同的方式使引用论文关联起来。例如，由总结性工作（例如，教科书、综述和软件工具包等）引领的网络通常具有图 3-10 (a-c) 所示的结构。它们的网络只在引领文章周围形成一个规则的圆环（环中的节点不相互引

用，只引用引领文章)。由更具创新性的研究文章引领的网络通常显示出更复杂的结构，如图 3-10 (d-f) 所示。不同的网络结构反映了目标出版物想法的不同演化模式。因此，科学 X 光将引领文章作为根节点，并从与其关联的引用网络中解码和可视化出思想流动的骨架结构 (图 3-9 (c))，这种结构被称为“思想树 (Idea Tree, IT)” (即引领文章的 X 光结果)。在思想树中，基于对应节点关联的子树结构的复杂性，知识熵 (Knowledge Entropy, KE) 被定义并用来量化文章的知识质量 (图 3-9 (d))。知识熵突出了目标文献想法的强大继承者，这使用户能够直观地感知想法是如何演化的。本文将想法树中包含 $KE \geq \omega$ (ω 为可以根据不同学科内文献数据多少进行调节的阈值，本文 ω 取 10) 的节点的层称为有效层 (Valid Layer, VL)，并将时间 t 时的有效层数定义为目标出版物在时间 t 的有效深度 (Valid Depth, VD)。最后，科学 X 光利用 VD 来量化引领文章想法的发展程度 (图 3-9 (e)) 并通过评估未来的 VD 还能增加多少以计算思想树的发展潜力指数 (Development Potential Index, DPI)，来量化目标想法的未来的发展潜力 (图 3-9 (f))。

3.2.2 目标出版物的思想树的提取

引用网络中存在大量冗余引用，对施引论文几乎没有学术影响。因此，需要移除重复的、无效的继承关系，以清晰、准确地重现思想流动，这可以通过评估论文之间的相似性来实现。理想情况下，本文假设网络中除引领文章之外的任何子文章都受到最重要引用 (相似性越高越重要) 的启发，从而使得科学 X 光能够得到一个揭示思想传承的思想树。通过这种方式，科学 X 光可以利用不同的思想树结构来表征思想的不同演化模式。从引用网络提取思想树有三个步骤。首先，将网络中的节点表示为高维空间中的向量。然后计算节点的简化指数 (Reduction Index, RI)，并根据简化指数的差异来衡量连接的重要性。最后，通过不断切断简化指数差异最大的节点对之间的边来得到思想树。

科学 X 光通过图嵌入来衡量高维空间中节点之间的距离。对于任何目标出版物，科学 X 光首先构建引用网络 $G(V, E)$ ，其中 V 表示所有节点的集合， E 表示所有边的集合。特别地， $p = |V|$ 被定义为网络中节点的数

量，而 $q = |E|$ 被定义为边的数量。 $\mathbf{A}$ 代表网络的邻接矩阵，形式为：

$$\mathbf{A} = \begin{pmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} & \dots & \mathbf{A}_{1p} \\ \mathbf{A}_{21} & \mathbf{A}_{22} & \dots & \mathbf{A}_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{A}_{p1} & \mathbf{A}_{p2} & \dots & \mathbf{A}_{pp} \end{pmatrix}, \quad (3.1)$$

其中 $\mathbf{A}_{ij} = 1$ 表示存在文献 v_i 引用文献 v_j 的引用关系，否则 $\mathbf{A}_{ij} = 0$ 。需要注意的是，目标论文在网络中不引用任何论文，因为它是最早发表的，这阻碍了后续对特征值和特征向量的计算。考虑到这一点，自引用或自环被引入到目标论文中，这允许后续的特征值分解。经过上述处理，带有自环的邻接矩阵 $\mathbf{W}$ 被得到：

$$\mathbf{W} = \begin{pmatrix} \mathbf{W}_{11} & \mathbf{W}_{12} & \dots & \mathbf{W}_{1p} \\ \mathbf{W}_{21} & \mathbf{W}_{22} & \dots & \mathbf{W}_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{W}_{p1} & \mathbf{W}_{p2} & \dots & \mathbf{W}_{pp} \end{pmatrix}, \quad (3.2)$$

其中当 $v_i \neq v_j$ 时， $\mathbf{W}_{ij} = \mathbf{A}_{ij}$ ，当 $v_i = v_j$ 且 $\sum_{j, j \neq i} \mathbf{A}_{ij} > 0$ 时， $\mathbf{W}_{ij} = 0$ ，当 $v_i = v_j$ 且 $\sum_{j, j \neq i} \mathbf{A}_{ij} = 0$ 时， $\mathbf{W}_{ij} = 1$ 。接着对带有自环的邻接矩阵 $\mathbf{W}$ 进行处理，带有自环的出度矩阵 $\mathbf{D}$ 被得到：

$$\mathbf{D} = \begin{pmatrix} d_1 & 0 & \dots & 0 \\ 0 & d_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & d_p \end{pmatrix}, \quad (3.3)$$

这是一个对角矩阵，其中 $d_i = \sum_j \mathbf{W}_{ij}$ 且 $d_i \neq 0$ 。接着对 $\mathbf{D}$ 进行处理，带有自环的归一化拉普拉斯矩阵 $\mathbf{L}_{normal}$ 被得到：

$$\mathbf{L}_{normal} = \mathbf{D}^{-\frac{1}{2}}(\mathbf{D} - \mathbf{W})\mathbf{D}^{-\frac{1}{2}}. \quad (3.4)$$

基于此, 科学 X 光对 $\mathbf{L}_{normal}$ 进行谱分解, 并得到任何节点 v 在高维空间中的嵌入 $e(v)$ 。具体地, 本文选择前 k 个特征值和相应的特征向量, 这表明科学 X 光将原始引文网络提升到 k 维空间。为了充分利用数据, 本文选择 $k = n$ 进行后续分析, 而现实世界中 k 可以从 2 到 n 中选择, 以减少海量数据的计算成本。因此, 在得到每个节点在高维空间的向量表示后, 对于任意两篇论文 v_i 和 v_j , 科学 X 光可以计算高维空间中论文之间的距离。

$$d_{ij}^{high} = \|e(v_i) - e(v_j)\|_2. \quad (3.5)$$

然后, 为了通过修剪引用网络获得思想树, 本文定义节点对整个网络的简化指数 (Reduction Index, RI) 来帮助移除冗余边。节点对整个网络的简化指数表征了节点代表的科学出版物的研究内容与整个引用网络的研究内容的相似性。因此, 两个节点对整个网络的简化指数的差异越大, 这两个节点的研究内容就越不相似, 相应地, 它们之间的边就越不重要。本文首先定义节点对之间的简化指数。对于节点对 (v_i, v_j) , 为了衡量 v_i 与 v_j 之间研究内容的相似性, 本文定义节点对的简化指数为从 v_i 到 v_j 的所有参考文献 $\mathcal{R}(v_j)$ 的加权迪杰斯特拉路径^[222]之和, 其中权重是路径上两个相邻节点在高维空间中的距离:

$$RI_{v_i, v_j} = \sum_{u \in \mathcal{R}(v_j)} \text{dijkstra}_{v_i, u}. \quad (3.6)$$

类似于 Symeonidis 等人^[223]的工作, 本文引入了加权最短路径来计算非邻居节点之间的相似性。本文也受到了“如果两个节点与一个相似的节点相连, 那么这两个节点是相似的”^[224]这一想法的启发。对于文章 v_j , 其引用列表中的文章可以被视为其思想的来源。因此, 可以认为文章 v_i 与 v_j 的引用列表中的文章越接近, 它就与文章 v_j 的研究内容越相似。

基于节点对的简化指数, 对于节点 v , 其对整个网络 G 的简化指数定义为其对网络中所有其他节点的简化指数之和:

$$RI_{v, G} = \sum_{u \in V/v} RI_{v, u}. \quad (3.7)$$

整个网络的简化指数帮助算法判断引用的重要性。两个节点对整个网络的简化指数的差异越大，它们之间的引用关系就越不重要。因此，科学 X 光通过简化指数的差异剪除不重要的引用，同时保持有向图条件下的连通性。最后，科学 X 光通过保留最重要的引用从引用网络中获得思想树。

3.2.3 思想树中文章知识质量的量化

思想树结构的形成是由不同知识质量的节点驱动的。因此，有效地衡量知识是揭示思想演化的基本问题。对于出版物，直接、有效和统一地评估知识质量几乎是不可能的，尤其是在没有任何经验的情况下。然而，思想树通过去冗余的过程保留了最有用的信息，而由节点引导的子树结构的复杂性差异表征了该节点中知识质量的差异。本文利用知识熵（KE）通过度量节点与思想树相关联的结构的复杂性来量化知识质量。为了定义知识熵，本文首先定义学术论文 a 的树熵（Tree Entropy, TE）如下：

$$TE(a) = -\frac{z_a}{2|E_{IT}|} \log \left(\frac{|V_a^{ST}|}{|V_{a^-}^{ST}|} \right). \quad (3.8)$$

树熵的定义遵循了^[225]中结构熵的定义，它借助划分树来度量嵌入在网络结构中的高维信息。在树熵中， z_a 表示思想树上节点 a 引领的子树中的节点到子树外原始引文网络中的节点的边的数量。 $|E_{IT}|$ 表示思想树中的边的数量。 z_a 越大，与 a 的子树相关联的结构就越复杂。因此， $\frac{z_a}{2|E_{IT}|}$ 项衡量了节点 a 的子树对整个思想树的重要性。 $|V_a^{ST}|$ 表示节点 a 引领的子树中的节点数量，而 $|V_{a^-}^{ST}|$ 表示 a 的父节点引领的子树中的节点数量。 $-\log \left(\frac{|V_a|}{|V_{a^-}|} \right)$ 项衡量了 a 的子树对其父子树的不确定性。一般来说，树熵可以衡量相应子树存在或不存在对整个思想树的不确定性的影响。在这种情况下，子树对思想树的影响越大，树熵就越大。根据上述树熵的定义，本文给出了互树熵（Mutual Tree Entropy, MTE）的定义如下：

$$MTE(a, b) = -\frac{z_{ab}}{4|E_{IT}|} \log \left(\frac{|V_a^{ST}| |V_b^{ST}|}{|V_{ab^-}^{ST}|^2} \right), \quad (3.9)$$

其中 z_{ab} 表示原始引用网络中从思想树上 a 和 b 引领的子树中的节点到这两个子树外的原始引文网络节点的边的数量。 $|E_{IT}|$ 表示思想树中的边的

数量。 $|V_a^{ST}|$ 表示节点 a 引领的子树中的节点数量, $|V_b^{ST}|$ 表示节点 b 引领的子树中的节点数量, 而 $|V_{ab}^{ST}|$ 表示 a 和 b 的父节点引领的子树中的节点数量, 这表明 a 和 b 应该有相同的父节点, 或者两个节点应该位于思想树中的相似位置。互树熵衡量两个子树中包含的知识的重叠程度。可以认为, 重叠的知识不是由这些子树创造的, 而是从父节点继承的。

基于上述的树熵和互树熵, 知识熵的定义如下: 在时间戳 t , 与目标出版物相关的引用网络为 $G^t = (V^t, E^t)$ 。从网络中提取的思想树为 $IdeaTree(G^t)$ 。对于属于 $IdeaTree(G^t)$ 的任何论文 v , 除了引领工作外, 本文定义思想树中所有节点的知识熵 $KE^t(v)$ 为:

$$KE^t(v) = TE^t(v) - \sum_{v_i \in \mathcal{S}^t(v)} TE^t(v_i) + \sum_{v_i, v_j \in \mathcal{S}^t(v), i \neq j} MTE^t(v_i, v_j), \quad (3.10)$$

其中 $TE^t(v)$ 表示在 t 时刻节点 v 引领的子树的树熵, $\mathcal{S}^t(v)$ 表示在 t 时刻 $IdeaTree(G^t)$ 中 v 的孩子节点集合, $MTE^t(v_i, v_j)$ 表示在 t 时由 v_i 和 v_j 引导的子树的互树熵。知识熵由两部分组成。第一部分 $TE^t(v) - \sum_{v_i \in \mathcal{S}^t(v)} TE^t(v_i)$ 是节点 v 的树熵减去其子节点的树熵, 这通过排除子节点 $\mathcal{S}^t(v)$ 的影响来量化节点 v 本身对思想树结构形成的影响。第一部分可能是负数, 这表明子节点对网络结构的影响大于父节点。第二部分 $\sum_{v_i, v_j \in \mathcal{S}^t(v), i \neq j} MTE^t(v_i, v_j)$ 从侧面利用互树熵反映了子节点 $\mathcal{S}^t(v)$ 从父节点 v 继承的知识量。尽管当父节点的知识被大量子节点继承时, **KE** 的第一部分可能是负的, 但大量子节点的出现会导致公式的第二项增加, 所以相应的父节点仍然被认为具有高知识质量。在实际计算中, 当公式的第二项非常小, 导致知识熵的值为负时, 考虑到科学文章的知识质量不能是负的, 科学 X 光直接将知识熵设为 0。在这种情况下, 文章既不足以影响结构, 也未能创造有价值的知识以被继承, 所以本文认为它具有低知识质量。

对于引领文章, 由于其没有父节点, 因此无法直接计算其树熵。然而, 考虑到树熵与知识熵之间的数值差异, 可以忽略树熵对知识熵的影响。因此, 对于引领文章 v_s , 其知识熵如下所示:

$$KE^t(v_s) = - \sum_{v_i \in \mathcal{S}^t(v_s)} TE^t(v_i) + \sum_{v_i, v_j \in \mathcal{S}^t(v_s), i \neq j} MTE^t(v_i, v_j). \quad (3.11)$$

其中 $\mathcal{S}^t(v_s)$ 表示在 t 时刻的 $IdeaTree(G^t)$ 中引领文章的子节点。

3.2.4 目标出版物思想的发展程度的量化

引领文章的思想通过吸引高影响力文章的跟进而得到发展和完善。对于思想树中的任何子节点，每次沿着从引领工作到该论文的连接路径继承思想时，都会在参考先前的想法后提出更完整的想法。就整个思想树而言，从引领工作开始，思想树的深度代表了原始思想改进的次数，这表征了引领文章思想的发展程度。知识熵帮助用户识别这种思想传承次数。在思想树的特定层出现高知识熵节点象征着改进工作的质的转变，从而标志着引领文章思想的实质发展。基于此本文称思想树中包含至少一个知识熵大于 ω 的节点的层为有效层 (Valid Layer)。对于 ω 取值，经过计算机科学、信息科学、地球科学等多个领域专家的判断，知识熵超过 10 的节点可以认为是目标论文的有效继承者，因此本文的 ω 取 10。需要说明的是， ω 取 10 只限于全领域数据，如需在特定领域上得到更精细的结果， ω 的值可以根据实际情况进行调整。基于定义的有效层与对实际可视化结果的观察，本文发现随着思想的演化，思想树更深的层会逐渐变得有效。因此，基于思想树和知识熵，在时间戳 t ，本文定义引领文章的思想树的有效层数为其思想发展程度的有效深度 (Valid Depth, VD^t)。

3.2.5 目标出版物思想的发展潜力的量化

本文认为有效深度的增加是由知识熵和时间衰减的综合效应驱动的。思想树中的高知识熵节点是有效深度增加的关键驱动因素。然而，对于具有高知识熵的节点，它们的思想将被后续工作不断传播和整合，这将导致它们促进有效深度增加的能力会随时间持续衰减。当知识熵的效果强于时间的衰减时，相应的文章将驱动有效深度的增加。然而，时间的衰减效应始终存在，类似于自然界中同位素的放射性随时间衰减。由于节点的知识熵不会持续增加，从长远来看，高知识熵节点的驱动效应将会在未来结束，然后对应思想的发展将停滞不前。本文基于猜想、拟合和验证得出了思想极限公式 (Idea Limit Formula, ILF)，用于定量描述节点推动思想树发展的效应，从而量化文章在思想树内的发展潜力。

公式的经验形式是： $\Delta D^t(v) = \log \frac{KE^t(v)}{(t-t_0)^\gamma}$ ，借助最小二乘法，本文

使用思想树的演化数据和知识熵数据作为样本数据来拟合时间衰减因子 γ 。对于任何思想树中的高知识熵节点 v ，节点 v 在 t_0 时变得可见，即 $KE^{t_0}(v) \geq \omega$ ，以节点 v 为起点，在 t_0 时由节点 v 引导的子树的有效深度为 0。已知直到当前时间 t_{now} ，由节点 v 引领的子树的最大有效深度 $MaxVD_{subtree_v}$ 是 $VD_{subtree_v}^{t_{now}}$ ，在 t_0 和 t_{now} 之间的任何时刻 $\bar{t}$ ， $\Delta D^t(v)$ 的样本数据 $\Delta D^{\bar{t}}(v) = MaxVD_{subtree_v} - VD_{subtree_v}^{\bar{t}}$ 可以被获取。同样，已知节点 v 在 $\bar{t}$ 时的知识熵是 $KE^{\bar{t}}(v)$ ，因此，样本数据 $(KE^{\bar{t}}(v_j), \bar{t}_i - t_0, \Delta D^{\bar{t}}(v_j))$ 可以从所有思想树被获取。通过变换，思想极限公式的形式被转换为： $\log KE^t(v) - \Delta D^t(v) = \gamma \log(t - t_0)$ ，其中 γ 的值根据最小二乘法获得：

$$\hat{\gamma} = \arg \min_{\gamma} \sum_{i,j} ((\log KE^{\bar{t}_i}(v_j) - \Delta D^{\bar{t}_i}(v_j)) - \gamma \log(\bar{t}_i - t_0))^2. \quad (3.12)$$

令目标函数对 γ 的导数为 0， $\hat{\gamma}$ 可以用等式 $\hat{\gamma} = \frac{\sum_{i,j} (\log KE^{\bar{t}_i}(v_j) - \Delta D^{\bar{t}_i}(v_j))}{\sum_{i,j} \log(\bar{t}_i - t_0)}$ 求得。本文基于拟合数据得到 γ 的值为 1.914。假设使思想树的某一层有效的最小知识熵为 $KE_{Threshold} = \omega$ ，节点 v 在 t_0 时变得可见，即 $KE^{t_0}(v) \geq \omega$ ，节点 v 在时间 t 后能为思想树激发的深度 $\Delta D^t(v)$ 满足：

$$\Delta D^t(v) \approx \log \frac{KE^t(v)}{(t - t_0)^{1.914}}. \quad (3.13)$$

其中 $\approx$ 表示得到的结果是估计值。基于 ILF，科学 X 光可以预测整个思想树在时刻 t 之后的未来有效深度增加 ΔD_{Tree}^t 。设 $\mathcal{B}^t$ 为思想树中所有满足 $KE^t(v) \geq \omega$ 的节点集合，当前思想树的有效深度为 VD^t ，对于任何 $v_i \in \mathcal{B}^t$ ，其在思想树中的有效层为 $VL_{v_i}^t$ ，根据思想极限公式，节点 v_i 在时刻 t 之后在有效层 $VL_{v_i}^t$ 能为思想树激发的有效深度是 $\Delta D^t(v_i)$ 。因此，对于整个思想树，科学 X 光使用 ΔD_{Tree}^t 来量化其发展潜力：

$$\Delta D_{Tree}^t = \max_{v_i \in \mathcal{B}^t} \{ \Delta D^t(v_i) - (VD^t - VL_{v_i}^t) \}. \quad (3.14)$$

本文将 ΔD_{Tree}^t 称为目标文章的发展潜能指数 (DPI)。因为 DPI 描述了思想树在未来增加其有效深度的潜力，其通常与 1 进行比较。DPI 大于或等于 1 的出版物被视为高发展潜力文章，DPI 越大，发展潜力越高。